

AMLLGuard

Manual de Estudo - Volume 6

Observability, Model Monitoring, Drift e Estrategia de Retraining

Fase	Dia	Resultado
Observabilidade e governanca	20	Pos-deployEndpoint monitorado, dados de inferencia coletados, drift analisado e politica de retrain

Objetivo deste volume: explicar, em linguagem simples e conectada ao projeto real, como o AMLGuard passou de um modelo apenas publicado em cloud para um sistema que tambem gera sinais sobre sua saude operacional e sobre mudancas no comportamento dos dados e das predicoes.

Mensagem central: colocar um modelo no ar nao encerra o ciclo de Machine Learning. Depois do deploy, precisamos observar o servico, observar o modelo, investigar mudancas e decidir com criterio quando treinar novamente.

Componente atual	Valor
Endpoint	amlguard-realtime
Deployment	blue
Modelo em serving	Azure ML Model Asset AMLGuard:1
Inference Environment	amlguard-inference:2
Threshold publico	0.892163
Data Collector	model_inputs + model_outputs, sampling_rate = 1.0

Importante: o batch usado para demonstrar drift no Dia 20 foi sintetico e deliberadamente variado. Os sinais significativos de PSI provam que o mecanismo de monitoramento consegue detectar mudancas; eles nao provam que ocorreu drift real em uma populacao de producao.

1. Depois do deploy: duas perguntas diferentes

Quando um endpoint esta online, existem pelo menos duas perguntas independentes. A primeira e: o servico esta funcionando bem? A segunda e: o modelo continua recebendo dados parecidos com aqueles para os quais foi validado e continua se comportando de forma aceitavel?

Camada	Pergunta	Exemplos de sinais
Observabilidade operacional	O servico esta saudavel?	requests, HTTP status, errors, latency, P50, P95, P99
Observabilidade do modelo	O comportamento do ML continua saudavel?	input distributions, score distribution, alert rate, data drift, p

Analogia do mundo real - hospital e paciente. A infraestrutura e como o predio e os equipamentos de um hospital: energia, elevadores, sistemas e tempo de atendimento precisam funcionar. O modelo e como o paciente: mesmo que o hospital esteja operacional, ainda precisamos acompanhar sinais vitais especificos. Um endpoint rapido pode estar servindo um modelo degradado; um modelo estatisticamente saudavel pode estar inacessivel por uma falha do servico.

Licao central: uptime e latencia nao substituem monitoramento de modelo; drift e alert rate tambem nao substituem monitoramento operacional.

Autoteste 1

1. Um endpoint com baixa latencia significa automaticamente que o modelo continua bom?

Nao. Isso demonstra saude operacional, nao qualidade estatistica ou generalizacao do modelo.

2. Um modelo sem drift pode estar indisponivel?

Sim. Falhas de infraestrutura e falhas de modelo pertencem a camadas diferentes.

2. Observabilidade operacional com Azure Monitor

O AMLGuard verificou as metricas nativas expostas pelo Azure Monitor para o Managed Online Endpoint. A intencao foi demonstrar que o servico produz telemetria observavel sem transformar um teste curto em um benchmark de capacidade.

Metrica	Unidade / funcao
RequestsPerMinute	volume de requisicoes observado
RequestLatency	latencia agregada em milissegundos
RequestLatency_P50	mediana aproximada da latencia
RequestLatency_P95	cauda de latencia para 95% das requisicoes
RequestLatency_P99	cauda extrema para 99% das requisicoes
DataCollectionEventsPerMinute	eventos de coleta do Model Data Collector
DataCollectionErrorsPerMinute	erros de coleta de dados

Por que P50, P95 e P99 importam

A media pode esconder experiencias ruins. Imagine 99 requisicoes respondendo rapidamente e uma demorando muito. A media aumenta um pouco, mas talvez nao revele claramente a cauda. Percentis ajudam a responder perguntas diferentes:

- P50: como se comporta uma requisicao tipica.
- P95: como se comportam as requisicoes mais lentas, excluindo apenas os 5% extremos.
- P99: ajuda a enxergar a cauda mais severa.

No teste controlado do Dia 20, foram observados pontos de RequestLatency de aproximadamente 15,5 ms e 16,33 ms; P50 de 25 ms e 18 ms; P95 de 26,5 ms e 18 ms; P99 de 26,5 ms e 18 ms.

Interpretacao correta: esses numeros demonstram que a telemetria de latencia funciona no endpoint. Eles nao constituem SLA, stress test ou benchmark de throughput.

O que foi realmente provado

- trafego bem-sucedido 2xx apareceu nas dimensoes do Azure Monitor;
- metricas de latencia estavam disponiveis e retornaram observacoes;
- o endpoint continuou respondendo depois da instrumentacao de coleta;

- nenhuma taxa de erro zero foi declarada sem evidencias suficientes.

3. Azure ML Model Data Collector: observar entradas e saidas

Para monitorar o comportamento do modelo, nao basta contar requests. Precisamos registrar, de forma controlada, o que entrou no modelo e o que saiu dele. O Dia 20 atualizou o deployment para o ambiente amlguard-inference:2 e habilitou o Azure ML Model Data Collector.

```
data_collector:
  sampling_rate: 1.0
  rolling_rate: Hour
  collections:
    model_inputs:
      enabled: "true"
    model_outputs:
      enabled: "true"
```

Colecao	Campos observados
model_inputs	Payment Format; Amount Paid; sender_previous_tx_count; is_business_hours; same_account
model_outputs	score; alert; threshold; model_version

O score.py coleta um DataFrame de entrada antes da inferencia e um DataFrame de saida depois da inferencia. A resposta externa continua com o mesmo contrato do Dia 19: score, alert, threshold e model_version.

Por que correlationid e importante

Cada observacao coletada possui um identificador de correlacao. Isso permite ligar uma entrada especifica a sua saida correspondente. Sem essa ligacao, poderiamos ter duas tabelas com o mesmo numero de linhas, mas sem garantia de qual predicacao pertence a qual request.

Validacao do Dia 20	Resultado
Registros de entrada	71
Registros de saida	71
Pares por correlationid	71
Somente entrada	0
Somente saida	0
Schema de entrada	PASS
Schema de saida	PASS
Correlation pairing	PASS

Licao central: coletar dados nao e suficiente. A coleta precisa ser validada quanto a schema, completude e pareamento entre input e output.

4. Tráfego sintetico para exercitar o monitoramento

O endpoint recebeu um lote determinístico de 70 requisições sintéticas, variando sete formatos de pagamento, valores, histórico do remetente e flags binárias. O objetivo não era simular fielmente o mundo real, mas criar uma população atual suficientemente diferente para exercitar o pipeline de monitoring.

Metрика do lote sintetico	Resultado
Requests planejadas	70
Sucesso	70
Falhas	0
Alertas	2
Alert rate do lote	2,86%
Score minimo	~0,000032
Score maximo	~0,964067

A coleção final possuía 71 observações porque, antes dessas 70 requisições, houve um smoke test pos-deploy. Esse smoke test também gerou alert = true. Por isso, a população coletada de 71 registros possui 3 alertas e alert rate de 4,23%, enquanto o lote isolado de 70 requests possui 2 alertas e 2,86%.

Armadilha conceitual: duas métricas podem estar corretas ao mesmo tempo quando medem populações diferentes. Sempre pergunte: qual é o denominador?

5. Data drift, prediction drift e PSI

Data drift significa que a distribuição das features mudou entre uma população de referência e uma população atual. Prediction drift significa que a distribuição dos scores ou previsões mudou.

No AMLGuard, a referência foi o test split determinístico usado pela pipeline congelada. A população atual foi composta pelos 71 registros coletados no endpoint durante o exercício do Dia 20.

PSI - Population Stability Index

O PSI resume quanto uma distribuição atual se afastou de uma distribuição de referência. O projeto usa a seguinte heurística didática:

PSI	Classificação no projeto
< 0,10	Low
0,10 a < 0,25	Moderate
>= 0,25	Significant

Esses limites são uma heurística do projeto, não uma lei universal. Em sistemas reais, os limites devem considerar o tipo de feature, volume, sazonalidade, risco do domínio e custo de falsos alarmes.

Resultados do exercício

Sinal	PSI	Classificação
Payment Format	0,666304	Significant
Amount Paid	3,304550	Significant

Sinal	PSI	Classificacao
sender_previous_tx_count	3,452996	Significant
is_business_hours	0,022415	Low
same_account	0,298780	Significant
Prediction score distribution	0,424604	Significant

O resultado geral foi classificado como significant. Isso era esperado porque o lote atual foi criado deliberadamente para ser diferente da referencia.

PASS no relatório significa que o pipeline de drift executou corretamente. Não significa "drift = zero" nem "modelo aprovado".

Autoteste 2

1. Um PSI significativo manda retreinar automaticamente?

Não. Ele dispara investigação; a decisão depende de persistência, representatividade, labels e impacto na qualidade.

2. Um relatório de drift pode passar e ainda reportar drift significativo?

Sim. PASS pode significar que o processo de medição foi executado e validado com sucesso.

6. Por que alert rate sozinho pode esconder mudanças

No exercício, o alert rate de referência foi aproximadamente 3,42% e o alert rate da população coletada foi 4,23%, uma mudança de apenas +0,81 ponto percentual. Mesmo assim, o PSI da distribuição de scores foi 0,424604, classificado como significativo.

Isso mostra uma situação importante: a proporção final de alertas pode mudar pouco porque o threshold continua cortando a distribuição em uma região parecida, enquanto a forma interna da distribuição de scores muda muito.

```
Reference scores  ---- distribution A ----> threshold 0.892163 ----> 3.42% alerts
Current scores   ---- distribution B ----> threshold 0.892163 ----> 4.23% alerts
```

```
Alert rate: small change
Score distribution: significant change
```

Lição central: monitorar apenas a quantidade de alertas pode mascarar prediction drift. Por isso, AMLGuard observa input distributions, score distribution e alert rate em conjunto.

7. Drift não e retraining: a estratégia de decisão

O Dia 20 documentou uma regra fundamental de governança: drift é um gatilho de investigação, não um gatilho automático de retraining e muito menos de deploy.

Fluxo mental

```
Monitoring signal
|
v
Is the window representative?
|
v
```

```

Does the signal persist?
|
v
Do we have enough ground truth?
|
v
Is there quality degradation or justified population shift?
|
v
Train candidate
|
v
Quality gates + regression comparison
|
v
Register only after PASS
|
v
Controlled deployment + post-deploy checks

```

Politica inicial do AMLGuard

- sinais devem persistir por tres janelas consecutivas antes de uma investigacao de retraining;
- smoke tests e batches sinteticos sao excluidos de decisoes de producao;
- e necessario volume de ground truth suficiente para avaliar qualidade;
- prediction PSI $\geq 0,25$ ou business-input PSI $\geq 0,25$ sao sinais de investigacao, nao autorizacao automatica;
- mudancas moderadas em multiplas features tambem podem justificar investigacao;
- mudanca material de alert rate precisa ser entendida em contexto operacional;
- erros ou degradacao de latencia pertencem primeiro a investigacao operacional.

Quality gates congelados continuam valendo

Gate	Valor
Average Precision minimo	0,035
Precision operating target	0,02
Recall minimo no operating point	0,65
Baseline	Nao pode ser alterado silenciosamente

Mesmo depois de retraining, um candidato nao recebe promocao apenas por ser novo. Ele precisa repetir o fluxo deterministico, passar quality gates, ser comparado com a baseline congelada, ser registrado somente apos PASS, ser validado quanto a compatibilidade de serving e passar verificacoes pos-deploy.

Decisao do batch sintetico do Dia 20: DO NOT RETRAIN.

8. Evidencias reais desta fase

Evidencia	O que comprova
docs/evidence/day20_operational_observability.json	telemetria operacional e latencia observadas
docs/evidence/day20_model_monitoring_traffic.json	70/70 requests sinteticas e resumo de scores/alerts

Evidencia	O que comprova
docs/evidence/day20_data_collection_validation.json	71 inputs, 71 outputs e pareamento completo
docs/evidence/day20_drift_report.json	PSI de features, prediction drift e alert-rate comparison
docs/evidence/day20_retraining_strategy.json	politica registrada e decisao DO NOT RETRAIN
docs/AZURE_MONITORING.md	documentacao tecnica consolidada do Dia 20
docs/RETRAINING_STRATEGY.md	regra de investigacao, retraining e promocao

Scripts reproduzíveis

```
scripts/monitoring/generate_day20_model_monitoring_traffic.py
scripts/monitoring/validate_day20_data_collection.py
scripts/monitoring/generate_day20_drift_report.py
```

Os JSONL brutos coletados foram usados apenas como dados temporarios de trabalho e nao devem ser versionados no repositorio. O repositorio preserva scripts e evidencias sanitizadas, nao credenciais nem identificadores sensitivos.

9. Definicao de pronto do Dia 20

Evidencia	Status
Azure Monitor metric definitions verificadas	Concluido
Trafego 2xx observado	Concluido
RequestLatency e P50/P95/P99 observados	Concluido
Inference Environment amlguard-inference:2 registrado	Concluido
Model Data Collector habilitado	Concluido
model_inputs e model_outputs persistidos	Concluido
71 pares input/output validados por correlationid	Concluido
70/70 requests sinteticas bem-sucedidas	Concluido
Alert rate e score distribution medidos	Concluido
Data drift calculado	Concluido
Prediction drift calculado	Concluido
Retraining strategy documentada	Concluido
Frozen quality gates preservados	Concluido
README e documentacao tecnica atualizados	Concluido
56 testes aprovados	Concluido
Ruff src/tests e codigo do Dia 20 aprovados	Concluido
git diff --check	Concluido

10. Resumo para entrevista

"No AMLGuard, depois de colocar o modelo em um Azure ML Managed Online Endpoint, implementei a camada de observabilidade. Usei Azure Monitor para acompanhar trafego e latencia, incluindo percentis P50, P95 e P99. Atualizei o serving para um ambiente com Azure ML Model Data Collector, coletando model_inputs e model_outputs sem alterar o contrato externo da API. Validei 71 pares de entrada e saida por correlation ID e criei um fluxo reproduzível para monitorar alert rate, distribuicao de scores, data drift e prediction drift com PSI. O teste de drift usou trafego sintetico, entao tratei os sinais como demonstracao do mecanismo e nao como evidencia de drift real. Tambem documentei uma estrategia de retraining em que drift dispara investigacao, mas qualquer candidato continua sujeito aos quality gates e regression gates congelados antes de registro ou promocao."

O que esta fase demonstra profissionalmente

O projeto passa a demonstrar, de forma verificavel, competencias de Azure Monitor, Azure ML Managed Online Endpoints, Model Data Collector, model observability, operational observability, data drift, prediction drift, PSI, alert-rate monitoring, score-distribution monitoring, retraining governance e gated model promotion.

Para recrutadores, o diferencial esta na conexao entre conceitos e evidencias: nao apenas dizer que conhece monitoring ou drift, mas mostrar configuracao, scripts, dados coletados, validacao de schema, relatorio de drift e uma politica explicita que impede retraining automatico irresponsavel.

11. Autoteste final

1. Qual e a diferenca entre observabilidade operacional e observabilidade do modelo?
2. Por que P95 e P99 podem revelar problemas que a media esconde?
3. Qual e a funcao do Model Data Collector no AMLGuard?
4. Por que correlationid e importante ao validar model_inputs e model_outputs?
5. Por que 2,86% e 4,23% de alert rate podem estar ambos corretos no Dia 20?
6. Qual e a diferenca entre data drift e prediction drift?
7. O que significa $PSI \geq 0,25$ neste projeto?
8. Um relatorio com status PASS significa ausencia de drift?
9. Por que o batch sintetico do Dia 20 nao pode autorizar retraining de producao?
10. Qual e a decisao correta quando aparece drift significativo?
11. Quais quality gates continuam protegendo a promocao de um novo candidato?
12. Como voce explicaria que alert rate quase estavel pode coexistir com prediction drift significativo?

Meta de estudo: responda as 12 perguntas sem consultar o manual. Depois explique o fluxo completo do Dia 20 em voz alta, desde a telemetria do endpoint ate a decisao DO NOT RETRAIN.

Checklist mental antes da proxima fase

- Consigo separar claramente falha de infraestrutura de degradacao de modelo.
- Consigo explicar o que P50, P95 e P99 representam.
- Consigo descrever como inputs e outputs foram coletados e pareados.
- Consigo interpretar PSI sem trata-lo como lei universal.
- Consigo explicar por que synthetic monitoring traffic nao representa producao.
- Consigo defender por que drift deve disparar investigacao, nao retraining automatico.

- Consigo recitar os quality gates congelados do AMLGuard.

Mensagem final do Volume 6: um sistema de ML maduro nao termina no deploy. Ele precisa observar o servico, observar o modelo, preservar evidencias e tomar decisoes de mudanca por regras auditaveis.